

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

RAPPORT DE PROJET

Atelier Pratique : E-commerce de Cadeaux

Segmentation, Prédiction du Churn et Estimation des Dépenses

Préparé par : MISSAOUI Yassine

Module : Machine Learning - GI2-S1

Encadré par : Madame Fadoua Drira

Date : 28 Avril 2026

Année Universitaire : 2025-2026

Table des matières

1	Introduction et Contexte	2
1.1	Contexte du Projet	2
1.2	Objectifs du Projet	2
1.3	Technologies Utilisées	2
1.4	Architecture du Projet	2
2	Description du Dataset	4
2.1	Vue d'Ensemble	4
2.2	Analyse RFM (Recency, Frequency, Monetary)	4
2.3	Features Catégorielles Principales	4
3	Prétraitement des Données	5
3.1	Gestion des Valeurs Manquantes	5
3.2	Traitement des Outliers	5
3.3	Pipeline de Prétraitement	5
3.4	Feature Engineering	6
4	Analyse Exploratoire des Données (EDA)	7
4.1	Matrice de Corrélacion	7
4.2	Observations Principales	7
4.3	Analyse des Valeurs Manquantes	8
5	Réduction de Dimensionnalité (ACP)	9
5.1	Objectif et Méthodologie	9
6	Clustering et Segmentation Client	10
6.1	Méthodologie K-Means	10
6.2	Interprétation des Clusters	10
7	Classification – Prédiction du Churn	11
7.1	Objectif	11
7.2	Performances Comparées des Modèles	11
7.3	Meilleur Modèle : XGBoost avec GridSearchCV	11
7.4	Matrices de Confusion	11
7.5	Courbes ROC	12
7.6	Importance des Features	12
8	Régression – Prédiction du Panier Moyen	13
8.1	Objectif	13
8.2	Performances des Modèles	13
8.3	Analyse des Résultats	13
9	Déploiement – Application Web et API	14
9.1	Architecture de Déploiement	14
9.2	Fonctionnalités Implémentées	14
9.3	Exemple de Réponse API	14
10	Conclusions et Perspectives	15
10.1	Résumé des Résultats	15
10.2	Points Forts du Projet	15
10.3	Perspectives d'Amélioration	15

1 Introduction et Contexte

1.1 Contexte du Projet

Ce projet s’inscrit dans le cadre du module **Machine Learning** du programme **GI2** pour l’année académique 2025-2026, encadré par Madame Fadoua Drira. L’objectif est d’appliquer des techniques avancées de Machine Learning pour analyser et prédire le comportement des clients d’une entreprise de vente en ligne spécialisée dans les cadeaux uniques et personnalisés.

L’entreprise fait face à plusieurs défis :

- Comprendre les différents profils de sa clientèle
- Identifier les clients à risque de départ (churn)
- Optimiser ses campagnes marketing ciblées
- Estimer la valeur potentielle de chaque client

1.2 Objectifs du Projet

Objectifs Principaux

1. **Prétraitement et nettoyage** des données clients brutes (52 features initiales)
2. **Analyse exploratoire approfondie** (EDA) avec visualisations statistiques
3. **Segmentation des clients** par clustering non supervisé (K-Means)
4. **Prédiction du churn** (départ des clients) par classification supervisée
5. **Estimation des dépenses moyennes** (MonetaryAvg) par régression
6. **Déploiement** d’une API REST et d’interfaces utilisateur interactives

1.3 Technologies Utilisées

Catégorie	Outils et Bibliothèques
Langage	Python 3.10+
Analyse de données	Pandas, NumPy
Visualisation	Matplotlib, Seaborn, Plotly
Machine Learning	Scikit-learn, XGBoost, Imbalanced-learn
API Backend	FastAPI, Uvicorn, Pydantic v2
Dashboard	Streamlit
Sérialisation	Joblib
Environnement	VS Code, Git, GitHub

1.4 Architecture du Projet

```
1 project_ml_retail/
2 |-- data/
3 |   |-- raw/                # Donnees brutes (CSV original - 2.28 MB)
4 |   |-- processed/          # Donnees nettoyees et encodees
5 |   |-- train_test/         # Datasets splittes (80/20 stratifie)
6 |   \-- predictions/        # Resultats des predictions
7 |-- src/
8 |   |-- preprocessing.py     # Pipeline de preparation des donnees
9 |   |-- train_model.py       # Entrainement et evaluation des modeles
10 |   |-- predict.py           # Service de prediction (singleton)
11 |   \-- utils.py             # Visualisations, metriques, utilitaires
12 |-- app/
13 |   |-- api.py               # API REST FastAPI documentee (Swagger)
14 |   |-- app.py               # Dashboard Streamlit autonome
15 |   \-- app_api.py           # Dashboard Streamlit connecte a l'API
```

```
16 |-- models/                # 8 artefacts ML sauvegardes (.pkl/.joblib)
17 |-- figures/               # 11 graphiques generes
18 |-- reports/               # Rapports et visualisations EDA
19 |-- notebooks/             # Notebook Jupyter d'exploration
20 |-- requirements.txt
21 |-- README.md
22 \-- .gitignore
```

Listing 1 – Structure du projet (arborescence)

2 Description du Dataset

2.1 Vue d'Ensemble

Le dataset provient d'une entreprise de e-commerce basée principalement au Royaume-Uni, spécialisée dans la vente de cadeaux personnalisés. Il contient des informations détaillées sur les transactions et comportements des clients sur la période 2009-2011.

Métrique	Valeur
Nombre total de clients	4 372
Nombre de features initiales	52
Nombre de features après ingénierie	84
Période couverte	2009 – 2011
Variable cible (Classification)	Churn (0 = fidèle, 1 = parti)
Variable cible (Régression)	MonetaryAvg (£)
Taux de churn global	~25% (classes déséquilibrées)

2.2 Analyse RFM (Recency, Frequency, Monetary)

L'analyse **RFM** constitue le socle de la compréhension client dans ce projet :

Indicateur	Description	Intervalle
Recency	Nombre de jours écoulés depuis le dernier achat	0 – 400 jours
Frequency	Nombre total de commandes distinctes	1 – 50+ commandes
MonetaryTotal	Montant total dépensé	-5 000£ à 15 000£
MonetaryAvg	Panier moyen par commande	5£ à 500£

2.3 Features Catégorielles Principales

Feature	Cardinalité	Valeurs
RFMSegment	4	Champions, Fidèles, Potentiels, Dormants
SpendingCategory	4	Low, Medium, High, VIP
CustomerType	5	Hyperactif, Régulier, Occasionnel, Nouveau, Perdu
Country	37+	United Kingdom, France, Germany, Australia...
Gender	3	M, F, Unknown
AccountStatus	4	Active, Suspended, Pending, Closed

3 Prétraitement des Données

3.1 Gestion des Valeurs Manquantes

Le dataset contenait des valeurs manquantes significatives, nécessitant des stratégies d'imputation adaptées :

Variable	% Manquant	Méthode	Justification
Age	~30%	Médiane par segment RFM	Robuste, préserve la segmenta
SupportTicketsCount	~5%	Détection valeurs aberrantes (-1, 999)	Correction ciblée
SatisfactionScore	~8%	Détection valeurs aberrantes (-1, 99)	Correction ciblée
Variables numériques	<5%	KNN Imputer (k=5)	Préserve les relations entre fea
Variables catégorielles	<10%	Mode	Simple, efficace, interprétable

3.2 Traitement des Outliers


Les valeurs aberrantes ont été détectées et traitées par la méthode de l'écart interquartile (IQR) :

Méthode IQR – Interquartile Range

1. Calcul de Q1 (25^epercentile) et Q3 (75^epercentile)
2. Calcul de l'IQR = Q3 – Q1
3. Bornes : [Q1 – 1.5 × IQR, Q3 + 1.5 × IQR]
4. Clipping des valeurs hors bornes (winsorisation)

Variables traitées : MonetaryTotal, TotalQuantity, MonetaryMin, MonetaryMax

3.3 Pipeline de Prétraitement



3.4 Feature Engineering

Plusieurs nouvelles features ont été créées pour enrichir l'analyse et améliorer les performances des modèles :

```
1 # Ratios financiers
2 df['AvgValuePerTransaction'] = df['MonetaryAvg'] / df['AvgQuantityPerTransaction']
3 df['MonetaryCV'] = df['MonetaryStd'] / (df['MonetaryAvg'].abs() + 1e-6)
4 df['ReturnRatioSquared'] = df['ReturnRatio'] ** 2
5
6 # Profondeur du panier
7 df['BasketDepth'] = df['AvgLinesPerInvoice'] / df['AvgQuantityPerTransaction']
8
9 # Taux d'annulation
10 df['CancellationRate'] = df['CancelledTransactions'] / (df['TotalTransactions'] + 1)
11
12 # Extraction depuis RegistrationDate
13 df['RegYear'] = pd.to_datetime(df['RegistrationDate']).dt.year
14 df['RegMonth'] = pd.to_datetime(df['RegistrationDate']).dt.month
```

Listing 2 – Exemples de features créées

4 Analyse Exploratoire des Données (EDA)

4.1 Matrice de Corrélation




FIGURE 1 – Matrice de corrélation des features numériques

4.2 Observations Principales

Constatats Clés de l'EDA

- **Forte corrélation positive** entre Frequency et MonetaryTotal ($r = 0.85$) : les clients fidèles dépensent davantage
- **Corrélation négative** entre Recency et la fidélité : plus un client est inactif longtemps, plus le risque de churn augmente
- **SupportTicketsCount** corrélé positivement avec le Churn : les réclamations répétées sont un signal d'alerte fort
- **ReturnRatio** élevé = signe d'insatisfaction = précurseur de churn
- **Distribution du Churn** déséquilibrée (75% fidèles / 25% churn) nécessitant une stratification lors du split

4.3 Analyse des Valeurs Manquantes




FIGURE 2 – Distribution des valeurs manquantes par colonne

5 Réduction de Dimensionnalité (ACP)

5.1 Objectif et Méthodologie

L'Analyse en Composantes Principales (ACP/PCA) a été appliquée pour :

- Réduire la dimensionnalité du dataset (84 features → 2-36 composantes)
- Visualiser les données clients en 2D
- Améliorer les performances du clustering K-Means
- Éliminer le bruit et la redondance (multicolinéarité)




FIGURE 3 – Variance expliquée par les composantes principales

Métrique	Valeur
Features originales	84
Composantes pour 95% de variance	36
Variance expliquée (2 composantes)	~25%
Algorithme	PCA (Scikit-learn)

TABLE 1 – Résumé des résultats de l'ACP

6 Clustering et Segmentation Client

6.1 Méthodologie K-Means

L'algorithme K-Means a été utilisé pour segmenter les clients en groupes homogènes. Le nombre optimal de clusters a été déterminé par :

1. **Méthode du coude (Elbow Method)** : analyse de l'inertie intra-cluster
2. **Score de Silhouette** : mesure de la cohésion et de la séparation des clusters

Métrique	Valeur
Nombre de clusters optimal (K)	2
Score Silhouette	0.16
Algorithme	K-Means (Scikit-learn)
Données utilisées	PCA (36 composantes)

TABLE 2 – Résultats du clustering K-Means

6.2 Interprétation des Clusters

Cluster 0 : Clients Fidèles Fréquence d'achat élevée Recency faible (< 50 jours) MonetaryTotal > 2 000£	Cluster 1 : Clients à Risque Achats occasionnels Recency élevée (> 150 jours) Potentiel de conversion
---	---

FIGURE 4 – Profils des segments clients identifiés par K-Means

7 Classification – Prédiction du Churn

7.1 Objectif

Prédire si un client va quitter l'entreprise (**Churn** = 1) ou rester fidèle (**Churn** = 0). Quatre algorithmes de classification ont été entraînés, évalués par validation croisée 5-fold et comparés.

7.2 Performances Comparées des Modèles

Modèle	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.92	0.81	0.73	0.77
Random Forest	0.95	0.87	0.81	0.84
Gradient Boosting	0.94	0.86	0.79	0.82
XGBoost (GridSearch)	0.96	0.90	0.84	0.87
Voting Classifier	0.95	0.88	0.82	0.85

TABLE 3 – Performances comparées des modèles de classification

7.3 Meilleur Modèle : XGBoost avec GridSearchCV

Hyperparamètres Optimaux – XGBoost

- `n_estimators` = 200
- `max_depth` = 5
- `learning_rate` = 0.1
- `subsample` = 0.8

Méthode d'optimisation : GridSearchCV avec validation croisée 5-fold et scoring F1.

7.4 Matrices de Confusion




FIGURE 5 – Matrices de confusion des deux meilleurs modèles

7.5 Courbes ROC




FIGURE 6 – Courbes ROC des modèles

7.6 Importance des Features




FIGURE 7 – Top features les plus importantes selon XGBoost

Top 5 Features Déterminantes pour le Churn

1. **Recency** : L'inactivité récente est le meilleur prédicteur
2. **Frequency** : La fidélité protège contre le churn
3. **ReturnRatio** : Taux de retour élevé = insatisfaction = risque
4. **SupportTicketsCount** : Tickets support = signal d'alerte précoce
5. **CustomerTenureDays** : L'ancienneté modère partiellement le risque

8 Régression – Prédiction du Panier Moyen

8.1 Objectif

Prédire le panier moyen (**MonetaryAvg**) des clients afin d'estimer leur valeur potentielle et d'optimiser les stratégies marketing (offres personnalisées, programmes de fidélité).

8.2 Performances des Modèles

Modèle	R ²	RMSE (£)	MAE (£)
Gradient Boosting	0.49	85.2	45.3
Random Forest	0.45	88.7	48.1
Ridge Regression	0.32	98.4	52.6

TABLE 4 – Performances comparées des modèles de régression

8.3 Analyse des Résultats

Le **Gradient Boosting Regressor** offre les meilleures performances avec un **R² de 0.49**, expliquant près de la moitié de la variance du panier moyen. Ce résultat est satisfaisant compte tenu de la complexité inhérente au comportement d'achat des clients.

Interprétation Métier

Les écarts les plus importants entre valeurs réelles et prédites s'observent pour :

- Les clients **VIP** à très fort panier moyen ($> 300\text{£}$)
- Les clients **très récents** avec peu d'historique d'achat
- Les clients avec un comportement d'achat **erratique**

9 Déploiement – Application Web et API

9.1 Architecture de Déploiement




FIGURE 8 – Architecture des applications de déploiement

9.2 Fonctionnalités Implémentées

Dashboard Streamlit (3 pages interactives)

- **Prédiction Simple** : Formulaire interactif avec jauge de risque de churn
- **Batch Prediction** : Upload CSV, prédictions en masse, téléchargement des résultats
- **Analyse des Risques** : Comparaison de profils clients types (faible/modéré/élevé/critique)
- **Informations Modèles** : Feature importance, métadonnées des modèles chargés

API REST FastAPI (5 endpoints)

Méthode	Endpoint	Description
GET	/	Statut général de l'API
GET	/health	Vérification santé (modèles chargés, features)
GET	/model/info	Métadonnées des modèles (type, nombre features)
POST	/predict	Prédiction unitaire enrichie (risque + recommandation)
POST	/predict/batch	Prédiction en lot avec tolérance aux erreurs

9.3 Exemple de Réponse API

```

1 {
2   "churn_prediction": 0,
3   "churn_probability": 0.1234,
4   "churn_risk_level": "Low",
5   "churn_risk_description": "Faible risque - Client fidele",
6   "churn_recommendation": "Maintenir l'engagement,
7                           programme de fidelite",
8   "timestamp": "2026-04-28T15:30:00"
9 }
  
```

Listing 3 – Réponse JSON de l'endpoint /predict

10 Conclusions et Perspectives

10.1 Résumé des Résultats

Étape du Pipeline	Résultat	Performance
Prétraitement	84 features créées, 0 valeurs manquantes	Pipeline 100% automatisé
ACP (PCA)	83 → 36 composantes	95% de variance conservée
Clustering (K-Means)	2 segments clients identifiés	Score Silhouette = 0.16
Classification (Churn)	XGBoost GridSearchCV	F1 = 0.87, AUC = 0.93
Régression (MonetaryAvg)	Gradient Boosting	R ² = 0.49, RMSE = 85.2£
Déploiement	API + 2 Dashboards	Swagger UI + Streamlit

TABLE 5 – Synthèse des résultats du projet

10.2 Points Forts du Projet

Réalisations Marquantes

- **Pipeline ML complet** : de l’exploration des données brutes au déploiement opérationnel
- **Comparaison systématique** : 4 classifieurs + 3 régresseurs évalués avec validation croisée
- **Optimisation poussée** : GridSearchCV 5-fold pour XGBoost (meilleur F1 = 0.87)
- **Triple interface** : API REST documentée (Swagger) + 2 dashboards Streamlit interactifs
- **Code modulaire et maintenable** : séparation claire preprocessing / training / prediction
- **Gestion de la production** : tolérance aux erreurs en batch, mode dégradé si modèles absents

10.3 Perspectives d’Amélioration

Pistes d’Évolution

1. **Deep Learning** : Tester des architectures neuronales (MLP, TabNet) pour la classification
2. **Régression avancée** : Optimisation bayésienne (Optuna) pour dépasser R² = 0.50
3. **Features temporelles** : Exploiter les séries temporelles pour détecter des motifs saisonniers
4. **Déploiement Cloud** : Conteneurisation Docker + CI/CD vers AWS/GCP
5. **Monitoring ML** : Suivi de la dérive des modèles (data drift, concept drift)
6. **A/B Testing** : Mesurer l’impact réel des recommandations sur la rétention client
7. **Explainabilité** : Intégrer SHAP/LIME pour expliquer chaque prédiction individuelle

Ce projet démontre l’application pratique et complète des techniques de Machine Learning pour résoudre des problématiques business concrètes dans le domaine du retail et de l’e-commerce.

Rapport réalisé par MISSAOUI Yassine
Machine Learning – GI2-S1 – 2025-2026
Encadré par Madame Fadoua Drira

Date de remise : 28 Avril 2026